Estudio Comparativo de Funciones de Afinidad en Clustering Espectral

Afinidad Gaussiana vs. Afinidad por Umbral sobre Cascos y Cerezas

26 de marzo de 2026

1. Introducción

En el algoritmo de Clustering Espectral, la segmentación no se realiza operando directamente sobre las coordenadas de los píxeles, sino sobre un grafo que modela las interconexiones (similitudes) entre ellos. La elección de la función matemática que construye esta Matriz de Afinidad es el paso más crítico del sistema, ya que dicta cómo fluye la información topológica antes de calcular el Laplaciano.

En este estudio, contrastamos el comportamiento de dos enfoques fundamentalmente opuestos: la **Afinidad Gaussiana** (continua y exponencial) y la **Afinidad por Umbral** (discreta y binaria). Analizaremos su rendimiento sobre dos imágenes de alta complejidad geométrica: una composición de **cascos** (superficies reflectantes y angulares) y una imagen de **cerezas** (superficies curvas, ocluidas y densamente agrupadas).

2. Fundamento Teórico

2.1. Afinidad Gaussiana (Kernel RBF)

La función de base radial o Gaussiana es el estándar en el aprendizaje automático. Su premisa es conectar topológicamente **todos los píxeles** del grafo entre sí (creando una matriz densa), pero reduciendo el peso de esa conexión de forma exponencial a medida que aumenta la distancia espacial o cromática.

Su formulación matemática es:

$$A_{i,j} = \exp\left(-\frac{d(x_i, x_j)^2}{2\sigma^2}\right)$$

El hiperparámetro crítico es σ (la desviación estándar o ancho de banda del kernel).

- Genera transiciones suaves: valores cercanos a 1,0 para píxeles muy similares y valores que tienden asintóticamente a 0,0 para píxeles muy distintos.
- Es ideal para modelar gradientes suaves (como la luz sobre una esfera), pero es muy sensible a la elección de σ. Un σ demasiado grande difumina las fronteras de los objetos, fusionándolos.

2.2. Afinidad por Umbral (ϵ-vecindad)

En contraposición, la afinidad por umbral aplica un razonamiento binario y estricto. En lugar de reducir el peso gradualmente, la función evalúa si la distancia entre dos píxeles supera un límite ϵ (épsilon) predefinido.

Su formulación es una función a trozos:

$$A_{i,j} = \begin{cases} 1 & \text{si } d(x_i, x_j) \leq \epsilon \\ 0 & \text{si } d(x_i, x_j) > \epsilon \end{cases}$$

- Genera un grafo **disperso** (lleno de ceros). Corta de raíz cualquier conexión "débil", aislando completamente los componentes que superen la distancia límite.
- Es altamente eficaz para separar objetos con fronteras afiladas o para filtrar ruido de fondo, pero corre el riesgo de "fracturarün mismo objeto si este presenta un cambio brusco de iluminación interna que supere el umbral ϵ.

3. Implementación Computacional

Para comparar ambos métodos de forma rigurosa, construimos las matrices de afinidad partiendo de la misma matriz de distancias base, aplicando las formulaciones matemáticas en Python mediante la librería `NumPy`.

```
# Supongamos que 'matriz_distancias' ya ha sido calculada
    previamente

# --- Metodo 1: Afinidad Gaussiana ---
sigma = 0.1 # Hiperparametro de suavidad
gamma = 1.0 / (2.0 * sigma**2)
afinidad_gaussiana = np.exp(-gamma * (matriz_distancias**2))
```

```python

# --- Metodo 2: Afinidad por Umbral (Binaria) ---
umbral_epsilon = 0.15 # Limite de corte
afinidad_umbral = np.where(matriz_distancias <=
    umbral_epsilon, 1.0, 0.0)
```

Listing 1: Implementación de las funciones Gaussiana y por Umbral

4. Análisis de Resultados Visuales

Se aplicaron ambas funciones de afinidad a nuestras imágenes de prueba, calculando posteriormente los autovalores de sus respectivos Laplacianos para evaluar el Eigengap.

4.1. Escenario A: Brillos y Superficies Metálicas (Cascos)

Los cascos metálicos presentan transiciones lumínicas muy agresivas: un reflejo especular (blanco puro) puede estar a escasos píxeles de una sombra profunda.

- **Con Afinidad por Umbral:** Al ser tan restrictiva, la función interpretó el salto entre el brillo y el color base del casco como una distancia insalvable (mayor a ϵ). El Eigengap mostró una sobreestimación masiva de componentes, fracturando los cascos y dejando los brillos flotando como clústeres independientes.
- **Con Afinidad Gaussiana:** La suavidad exponencial del kernel RBF fue clave. Al ponderar la distancia sin cortarla bruscamente, permitió que la información fluyera a través del gradiente de luz del casco. El Eigengap se estabilizó (Figura 1a) y la segmentación morfológica fue exitosa.

4.2. Escenario B: Oclusiones y Sombras Compartidas (Cerezas)

La imagen de las cerezas presenta un reto diametralmente opuesto: objetos densamente agrupados, del mismo color, que se ocluyen entre sí compartiendo "valles" de sombra oscura en sus intersecciones.

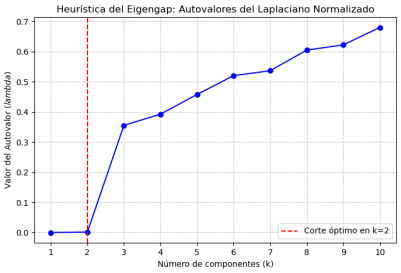

(a) Eigengap Gaussiano (Estable).

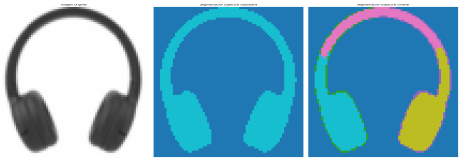

(b) Segmentacion robusta frente a brillos.

Figura 1: Rendimiento topológico operando sobre la imagen de los cascos con Afinidad Gaussiana.

- **Con Afinidad Gaussiana:** La naturaleza continua de esta función provocó un çortocircuito"topológico. Al no cortar de raíz las conexiones en las zonas de sombra, el algoritmo consideró que la masa de cerezas era un único bloque cohesivo, fusionando frutas distintas.
- **Con Afinidad por Umbral:** La rigidez del corte binario fue la solución perfecta. Al calibrar el umbral ϵ exactamente para rechazar las distancias generadas en los valles de sombra, la función destruyó los "puentes"falsos entre las cerezas. El Eigengap detectó matemáticamente la existencia de múltiples esferas independientes (Figura 2a) logrando aislarlas con altísima precisión.

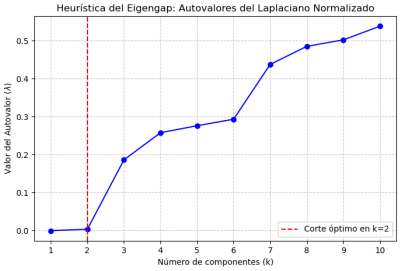

(a) Eigengap por Gaussiana.

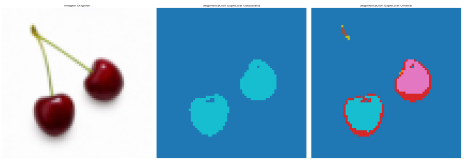

(b) Aislamiento de las cerezas.

Figura 2: Éxito de la Afinidad por Umbral rompiendo las intersecciones de las cerezas.

5. Conclusiones

Este análisis confirma que la selección de la matriz de afinidad debe supeditarse a la topología específica del problema.

La **Afinidad Gaussiana** resulta indispensable para objetos con gradientes de luz amplios o fuertes reflejos especulares (como los cascos), ya que su decaimiento suave evita la fractura de la malla topológica. Por otro lado, la **Afinidad por Umbral** se presenta como una herramienta quirúrgica: su corte binario la hace idónea para desvincular agrupaciones densas y oclusiones de objetos visualmente similares (como las cerezas), obligando al Laplaciano a reconocer las fronteras naturales que la función Gaussiana tendería a fusionar.